TD n°2 : Statistique descriptive

Exercice 1 :

Une étude a examiné le temps d'induction entre la méningite bactérienne et l'apparition des crises d'épilepsie chez 13 patients (en mois). Les données sont les suivantes :

0.10, 0.25, 0.50, 4, 12, 12, 14, 24, 31, 36, 42, 55, 96.

1. Calculez la moyenne, le mode, la médiane, la variance, ainsi que l'écart type de cet ensemble de données.
2. Comparez la moyenne et le mode. Que cela vous dit-il sur la forme de la distribution ?
3. Quelle mesure de tendance centrale utiliseriez-vous pour décrire le centre de cette distribution ? Expliquez votre réponse.
4. Calculez les quartiles et les interpréter. Calculez l'écart interquartiles, ainsi que le coefficient d'asymétrie de Yule. Que peut-on déduire ?
5. Construisez un boxplot pour ces données. Y a-t-il des valeurs aberrantes (extrêmes) ?
6. Le boxplot montre-t-il des signes d'asymétrie ?

Exercice 2 :

Les niveaux de pression artérielle de 60 étudiants en première année de médecine millimètres de mercure (mm Hg) - 1 mmHg correspond à une pression d'environ 133 pascals ou 0,00133 barsont présentés dans le tableau ci-dessous :

Limites de classe (mm Hg)	**Effectif**
[90 , 100[	2
[100 , 110[	6
[110 , 120[	17
[120 , 130[	16
[130 , 140[	12
[140 , 150[	6
[150 , 160[	1

TABLE 1 – Pression artérielle des étudiants (n = 60)

1. Calculez la moyenne, le mode, la médiane, la variance, l'écart type, ainsi que le coefficient de variation de cet ensemble de données.
2. Calculer le coefficient d'asymétrie de Pearson. Que peut-on dire de la forme de la distribution ?
3. Calculez les quartiles et les interpréter. Calculez l'écart interquartiles, ainsi que le coefficient d'asymétrie de Yule. Que peut-on déduire ?

4. Construisez un boxplot pour ces données.
5. Le boxplot montre-t-il des signes d'asymétrie ?

Exercice 3 :

Dans une étude épidémiologique, on cherche à analyser la relation entre le **nombre de jours d'exposition** à un agent infectieux et le **nombre de symptômes** observés chez un groupe de patients. Les données sont regroupées dans le tableau croisé suivant :

Nombre de jours d'exposition (X)	**Nombre de symptômes (Y)**			**Total**
	1 symptôme	**2 symptômes**	**3 symptômes**	
2 jours	10	15	0	25
4 jours	0	12	18	30
6 jours	0	0	25	25
Total	10	27	43	80

TABLE 2 – Tableau croisé des données d'exposition et de symptômes

1. Calculez la moyenne de X (nombre de jours d'exposition) et de Y (nombre de symptômes).
2. Les deux variables X et Y sont-elles indépendantes ?
3. Calculez la covariance entre X et Y.
4. Interprétez la covariance obtenue. Que pouvez-vous conclure sur la relation entre le nombre de jours d'exposition et le nombre de symptômes ?

Exercice 4 :

Cet exercice utilise des données d'une étude importante par Richard Doll, publiée en 1955. Cette étude a examiné les taux de mortalité associés au cancer du poumon par région, en fonction de la consommation de cigarettes par habitant (variable explicative). Le tableau suivant présente la consommation de cigarettes par habitant en 1930 (cig1930) et cas de cancer du poumon pour 100 000 habitants en 1950 (LUNGCA) dans 11 pays.

1. Représenter graphiquement le nuage de point. Que peut-on dire de la relation entre la consommation de cigarettes et le cancer du poumon ?
2. Calculer la variance de chaque variable, ainsi que la covariance et le coefficient de corrélation entre les deux variables.
3. Déterminer la droite de régression linéaire de LUNGCA en CIG1930.
4. Un danois consommait en moyenne 380 cigarettes en 1930. Donner une estimation du nombre de cas de cancer du poumon (en 1950).

Pays	CIG1930	LUNGCA
États-Unis	1300	20
Grande-Bretagne	1100	46
Finlande	1100	35
Suisse	510	25
Canada	500	15
Pays-Bas	490	24
Australie	480	18
Suède	300	11
Norvège	250	9
Islande	230	6

TABLE 3 – Consommation de cigarettes par habitant en 1930 et cas de cancer du poumon pour 100 000 en 1950.

TD n°2

EX1

1/ la moyenne. $\overline{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{1}{n}\sum_{i=1}^{p} n_i \cdot x_i$

$\overline{x} = \frac{1}{13}(0,1 + 0,25 + 0,5 + 4 + 12 + 12 + 14 + 24 + 31 + 36 + 42 + 58 + 96)$.

$\overline{x} = 25,14$ mois

Le mode. Le mode c'est la valeur 12 mois (c'est la qui a la plus grand effectif).

la médiane. $n = 13$

si Impaire $\Rightarrow$ $Me = \frac{x_{n+1}}{2} \Rightarrow Me = \frac{x_{13+1}}{2} = \frac{x_{14}}{2} = x_7$

$= 14$ mois

si paire $\Rightarrow$ $Me = \frac{x_p + x_{p+1}}{2}$ $\quad p = \frac{n}{2}$

La variance $\Rightarrow$

$Var(x) = \frac{1}{n}\sum_{i=1}^{n}(x_i - \overline{x})^2 = \frac{1}{n}\sum_{i=1}^{p} n_i (x_i - \overline{x})^2$

$= \left(\frac{1}{n}\sum_{i=1}^{n} x_i^2\right) - \overline{x}^2 = \left(\frac{1}{k}\sum n_i x_i^2\right) - \overline{x}^2$

$\sigma(x) = \sqrt{Var(x)}$

① $Var(X) = \frac{1}{13}\left((0,1-25,14)^2 + (0,25-25,14)^2 + (0,5-25,14)^2 + (4-25,14)^2 + (12-25,14)^2 + (12-25,14)^2 + (14-25,14)^2 + (24-25,14)^2 + (31-25,14)^2 + (36-25,14)^2 + (42-25,14)^2 + (55-25,14)^2 + (96-25,14)^2\right)$

$Var(X) = 701,7 \text{ mois}^2$

② $Var(X) = \left(\frac{1}{13}\left((0,1)^2 + (0,25)^2 + (0,5)^2 + (4)^2 + (12)^2 + (12)^2 + (14)^2 + (24)^2 + (31)^2 + (36)^2 + (42)^2 + (55)^2 + (96)^2\right) - (25,14)^2\right)$

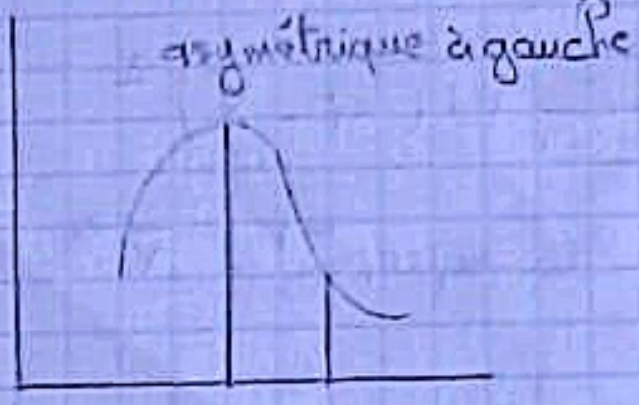
$Var(X) = 701,7 \text{ mois}^2$

$\sigma(X) = \sqrt{Var(X)}$

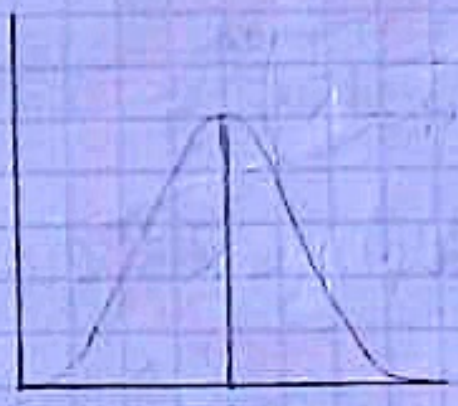
$= \sqrt{701,7}$

$\sigma(X) = 26,49 \text{ mois}$

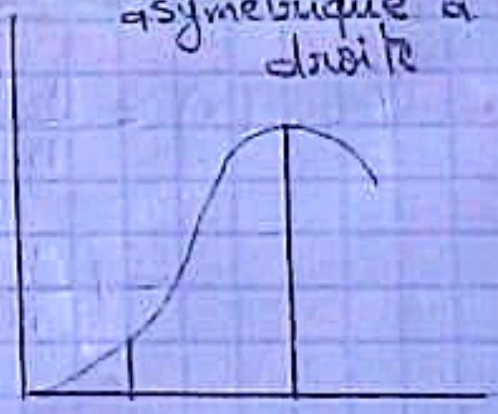
2/



étalée à droite



asymétrique



étalée à gauche.

On a $\bar{x} >$ mode $(25,14 > 12)$, donc la courbe est étalée à droite

3/ La mesure de tendance centrale qui on peut utilisée est la médiane.

1.2.t.c

4/ $Me = \frac{x_{14} + x_{15}}{2} = x_7 = 14$ mois

$Q_2 = Me = 14$ mois (2ème)

étape 1 : $\frac{n}{4} = \frac{13}{4} = 3,25$

$Q_1 = x_{\frac{n}{4}} \Rightarrow Q_1 = x_4$

$Q_1 = x_4 = 4$ mois (1er)

$Q_3 = x_{10} = 36$ mois (3ème)

$\frac{3n}{4} = \frac{3 \times 13}{4} = \frac{39}{4} = 9,75$ → 10

- L'écart interquartiles $Q_3 - Q_1 = 36 - 4 = 32$ mois.

- Le coefficient d'asymétrie de Yule :

$$Y = \frac{Q_1 + Q_3 - 2Me}{Q_3 - Q_1}$$

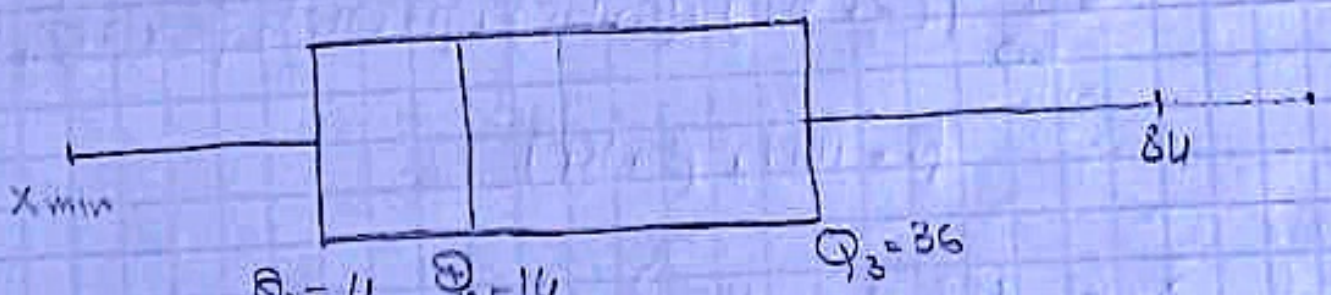
$Y = 0$: série symétrique

$Y > 0$: étalée à droite

$Y < 0$: étalée à gauche.

$Y = \frac{4 + 36 - (2 \times 14)}{32} = 0,375 > 0$ étalée à droite.

5/



4 plus proche à 14 qu'à 36.

Pour calculer les bornes

x_{min} : $Q_1 - 1,5(Q_3 - Q_1) \Rightarrow (-1,5 ; 44) \Rightarrow -1,5$

↳ On choisit le max entre ces 2 valeurs.

x_{max} : $Q_3 + 1,5(Q_3 - Q_1) \Rightarrow (96 ; 84) \Rightarrow 84$.

↳ On choisit le min entre ces valeurs :

La valeur 96 est une valeur aberrante, car elle dépasse la borne de boxplot.

6/ Le boxplot est asymétrique à gauche.

Exercice 2 :

Poids de classe (mmHg).	[90;100[	[100;110[	[110;120[	[120,130[	[130,140[	[140;150[	[150;160[
Effectif : n_i	2	6	17	16	12	6	1
Fréquence : f_i	$2/60 \times 100 = 3,33$	$6/60 \times 100 = 10$	$17/60 \times 100 = 28,33$	$16/60 \times 100 = 26,66$	$12/60 \times 100 = 20$	$6/60 \times 100 = 10$	$1/60 \times 100 = 1,66$
Fréquence Cumulé : F_i	$2/60 \times 100 = 3,33$	$8/60 \times 100 = 13,33$	$25/60 \times 100 = 41,66$	$41/60 \times 100 = 68,33$	$53/60 \times 100 = 88,33$	$59/60 \times 100 = 98,33$	$60/60 \times 100 = 100$
N_i	2	2+6 = 8	8+17 = 25	25+16 = 41	41+12 = 53	53+6 = 59	59+1 = 60
$C_i = m_i$	95	105	115	125	135	145	155

⇓ $[a_1 ; a_2[$

$m_i = C_i = \frac{a_1 + a_2}{2}$

1/ Le moyenne : $\overline{x} = \frac{1}{n} \cdot \sum n_i m_i$

$= \frac{1}{60} ((2 \times 95) + (6 \times 105) + (17 \times 115) + (16 \times 125) + (12 \times 135) + (6 \times 145) + (1 \times 155))$

$\overline{x} = 123,7$ mmHg

Le mode :

La classe modale est $[110;120[$ M₀ ∈ $[110,120[$

$M_0 = 110 + (120 - 110) \times \frac{17-6}{(17-6)(17-16)}$

$M_0 = 119,17$ mmHg

La médiane : la classe médiane c'est [120, 130[

$$Me = 120 + (130 - 120) \times \frac{30 - 25}{41 - 25}$$

$Me = 123,125$ mmHg

$\bar{x} = 123,7$ mmHg

$Mo = 119,17$ mmHg

$Me = 123,125$ mmHg

$\sigma = 12,78$ mmHg

$$\sigma(x) = \sqrt{Var(x)}$$

$$Var(x) = \left(\frac{1}{n}\sum x_i^2\right) - \bar{x}^2$$

$$Var(x) = \frac{1}{n}\sum (x_i - \bar{x})^2$$

2/ $$\gamma = \frac{\bar{x} - Mo}{\sigma} = \frac{123,7 - 119,17}{12,78}$$

$= 0,35$

Coefficient d'asymétrie de Pearson.

La distribution est légèrement asymétrique elle asymétrique à gauche (étalée à droite).

3/ $Q_2 = Me$ → $123,125$ mmHg

La classe médiane $[a_i, a_{i+1}[$

$$Me = a_i + (a_{i+1} - a_i) \times \frac{\frac{n}{2} - N_{i-1}}{N_i - N_{i-1}}$$

$Q_1 \in [110, 120[$ $\frac{n}{4}$ $\frac{60}{4} = 15$

$$Q_1 = 110 + (120 - 110) \times \frac{\frac{n}{4} - 8}{25 - 8}$$

$n = 60$

[الصف الأول - الصف الثاني] الصفوف

$Q_1 = 114,11$ mmHg

$Q_3 \in [130, 140[$ $\frac{3n}{4}$ $Q_3 = 130 + (140-130) \times \frac{45-41}{53-41}$

$$\boxed{Q_3 = 133,33 \text{ mmHg}}$$

Plus l'écart est grand plus la Valure : est dispersé.

Ecart quartile = D

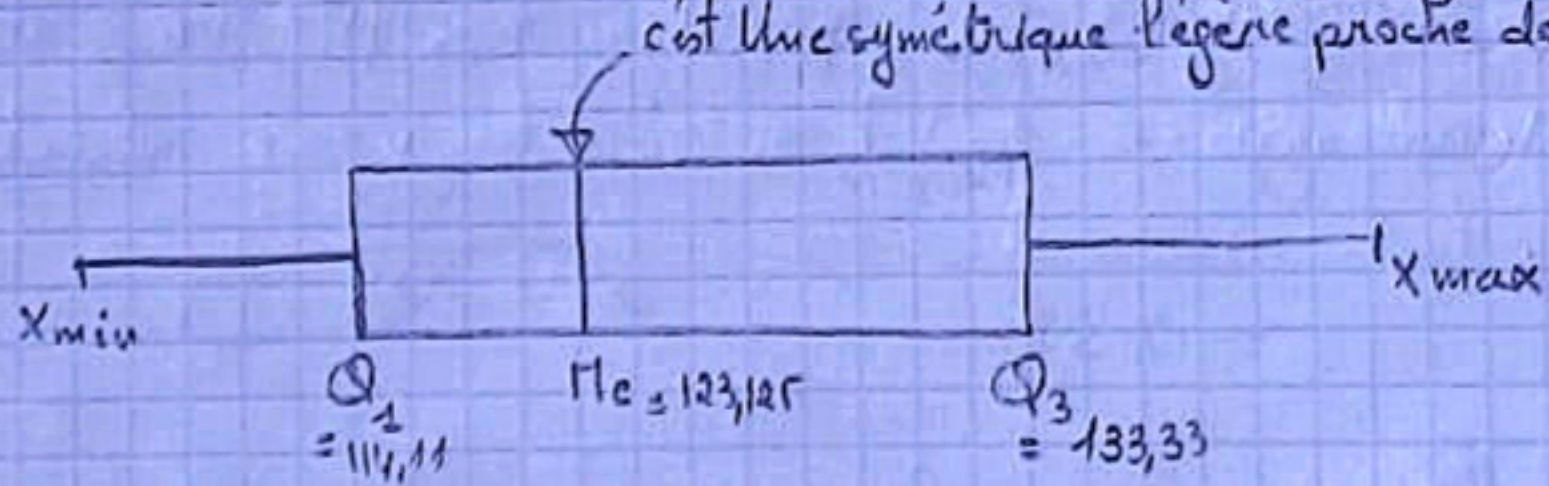
$$EQ = Q_3 - Q_1 = 133,33 - 114,11$$

$$\boxed{EQ = 19,22 \text{ mmHg}}$$

$$\gamma = \frac{Q_1 + Q_3 - 2Me}{Q_3 - Q_1} = \frac{(114,11 + 133,33) - (2 \times 123,125)}{19,22}$$

$$\boxed{\gamma = 0,061}$$

4/



On fait la Comparaison entre : $\begin{cases} \underbrace{X_{min}}_{90} \text{ : et } \underbrace{Q_1 - 1,5(Q_3 - Q_1)}_{85,28} \text{ et on prend le plus grand.} \\ \text{Puis entre :} \\ X_{max} \text{ : et } Q_3 + 1,5(Q_3 - Q_1) \text{ et on prend le plus petit} \end{cases}$

Pas Valeurs extrêmes = D

5/ le boxplot est asymétrique à gauche : C'est Une symétrie très légère.

Exo 8

x_i	2	4	6	Totale
$n_{i\cdot}$	25	30	25	80

$$\bar{X} = \frac{1}{80}\sum_{i=1}^{3} n_i x_i = \frac{1}{80}\left(2\times 25 + 4\times 30 + 6\times 25\right).$$

$\bar{X} = 4$ jours

y_j	1	2	3	Totale
$n_{\cdot j}$	10	27	43	80.

$$\bar{Y} = \frac{1}{80}\sum_{j=1}^{3} n_j y_j = \frac{1}{80}\left(1\times 10 + 2\times 27 + 3\times 43\right)$$

$\bar{Y} = 2,41$

2/ x et y sont indépendantes $\Rightarrow n_{ij} = \dfrac{n_{i\cdot} \times n_{\cdot j}}{n}$ $\left(\begin{matrix}\forall i=1\to 3\\ \forall j=1\to 3\end{matrix}\right)$

Pour $i = j = 1$.

$$n_{11} \neq \frac{n_{1\bullet} \times n_{\cdot 1}}{n} \quad \text{Car } 10 \neq \frac{25\times 10}{80} = \frac{250}{80} = \frac{25}{8}$$

$\Rightarrow$ x et y ne sont pas indépendants, elle sont dépendants.

3/ $\text{Covariance}(x,y) = \frac{1}{n}\sum_i\sum_j n_{ij}(x_i-\bar{x})(y_j-\bar{y})$ (1)

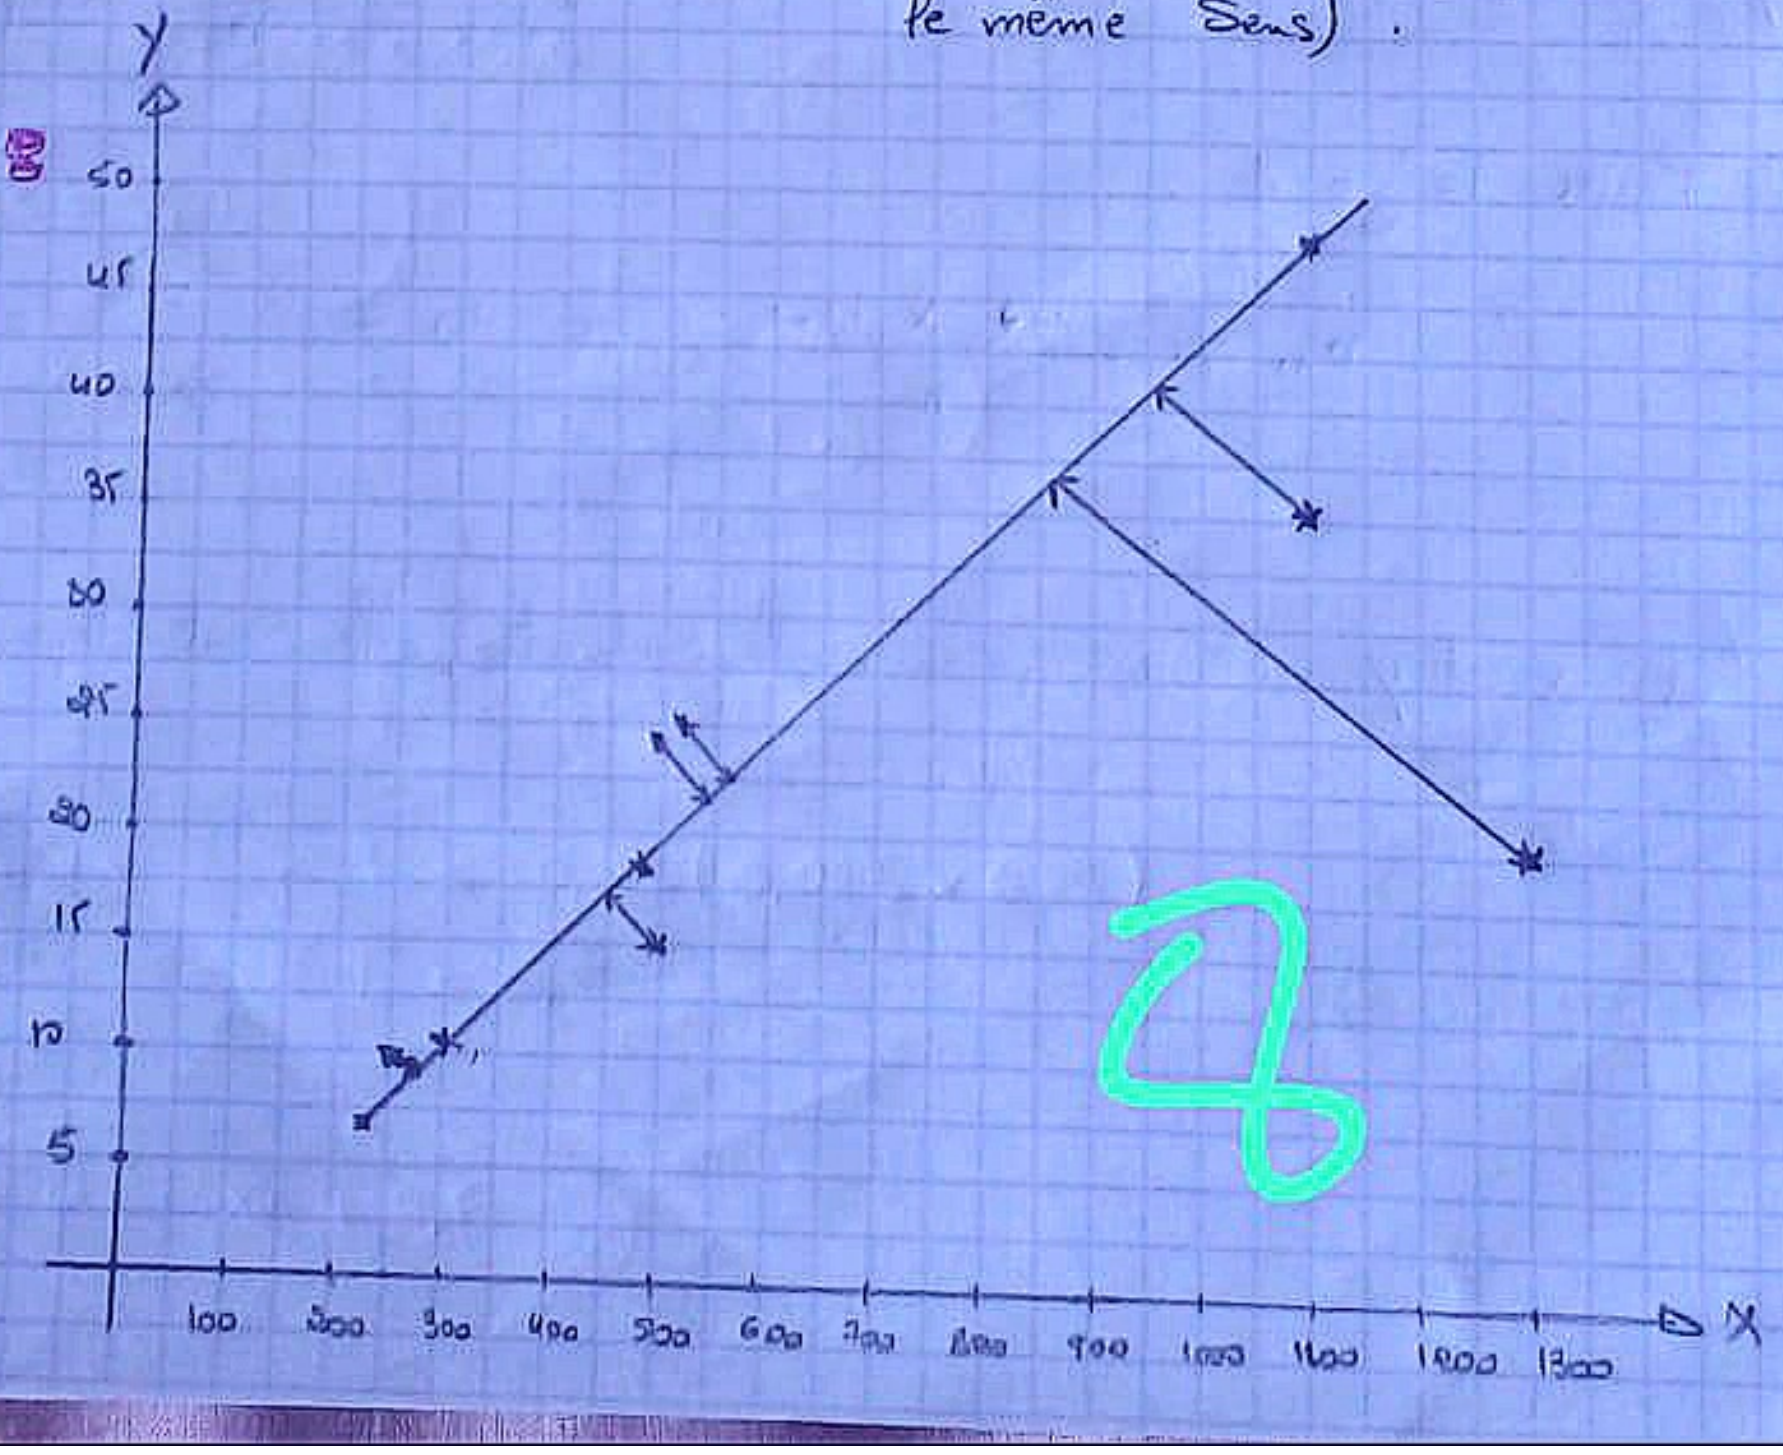
$\text{Covariance}(x,y) = \left(\frac{1}{n}\sum\sum n_{ij}x_i y_j\right) - \bar{x}\bar{y}$ (2)

$$Cov(x,y) = \left(\frac{1}{n}\sum\sum n_{ij}x_i y_j\right) - \bar{x}\bar{y}$$

$$= \left(\frac{1}{80}\left(10\times1\times2 + 15\times2\times2 + 0\times3\times2 + 0\times1\times4 + 12\times2\times4 + 18\times3\times4 + 0\times1\times6 + 0\times2\times6 + 25\times3\times6\right)\right) - 4\times 2{,}41.$$

$Cov(x,y) = 0{,}88$

4/ ona $Cov(x,y) > 0$ indique que la relation entre les variables x et y est positive (c'est-à-dire elles varient dans le même sens).



Ex4 B

4

2/ $\bar{x} = \frac{1}{n}\sum x_i = \frac{1}{10}(1300 + 1100 + 1100 + 510 + 500 + 490 + 480 + 300 + 270 + 230)$.

$\bar{x} = 626$.

$\Rightarrow Var(x) = \left(\frac{1}{n}\sum x_i^2\right) - \bar{x}^2$

$= \frac{1}{10}(1300^2 + 1100^2 + 1100^2 + 510^2 + 500^2 + 490^2 + 480^2 + 300^2 + 270^2 + 230^2) - 626^2$

$Var(x) = 137724$

$\bar{y} = \frac{1}{n}\sum y_j = \frac{1}{10}(20 + 46 + 35 + 25 + 15 + 24 + 18 + 11 + 9 + 6)$

$\bar{y} = 20,9$

$\Rightarrow Var(y) = \left(\frac{1}{n}\sum y_j^2\right) - \bar{y}^2$

$= \frac{1}{10}(20^2 + 46^2 + 35^2 + 25^2 + 15^2 + 24^2 + 18^2 + 11^2 + 9^2 + 6^2) - 20,9^2$

$Var(y) = 136,09$

la Covariance :

$$Cov(x,y) = \left(\frac{1}{n}\sum_i \sum_j n_{ij} x_i y_j\right) - \bar{x}\bar{y}$$

on a $\bar{x} = 626$
$\bar{y} = 20,9$

$$Cov(x,y) = \left(\frac{1}{10}\left(6\times 230 + 9\times 250 + 11\times 300 + 15\times 500 + 18\times 480 + 20\times 1300 + 24\times 490 + 25\times 510 + 35\times 1100 + 46\times 1100\right)\right) - 626 . 20,9$$

$$Cov(x,y) = 3184,6$$

Le Coefficient de Corrélation :

$$r = \frac{Cov(x,y)}{\sigma x . \sigma y}$$

$$\sigma x = \sqrt{Var(x)} = \sqrt{137724} = 371,1$$
$$\sigma y = \sqrt{Var(y)} = \sqrt{136,09} = 11,66$$

donc $r = \dfrac{3184,6}{371,11 \times 11,66}$

$$r = 0,73$$

3/ $y = ax + b \Longrightarrow a = \dfrac{Cov(x,y)}{Var(x)}$ → positive.

$$a = \frac{3184,6}{137724}$$

$$a = 0,023$$

$$b = \bar{y} - a\bar{x} \Longrightarrow b = 20,9 - (0,023 \times 626)$$

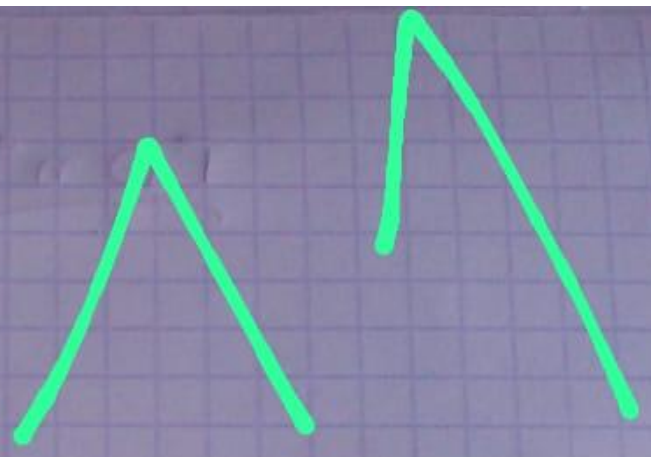
$$b = 6,5$$

donc $y = 0,023x + 8,5$

4/ ona $x = 380$

Alors $y = (0{,}023 \times 380) + 6{,}5$

$y = 15{,}2$



=> l'estimation du nombre de Cas de Cancer du poumon en 1950 pour Un Dansisyant Consommé en moyenne 380 Cigarettes en 1930 est d'envison 15,2 Cas Pour 100 000 Habitants.