



Probabilité et Statistique

JOUDAR Nour-Eddine
nouredine.joudar@usmba.ac.ma

2025/2026

Sommaire

1 Introduction

2 Statistique descriptive

3 Probabilité

3.1 Probabilité conditionnelle

3.2 Variables aléatoires multidimensionnels

3.3 Lois usuelles

4 Ajustement statistique - principe des moindres carrés

5 Estimation et tests statistiques

6 Processus stochastique





Introduction

Statistique
Descriptive

Probabilité

Ajustement

Estimation



Introduction

- **Question:** Pourquoi un cours de statistiques ?

Intérêt des statistiques

Réponse: La résolution d'un grand nombre de problèmes au différentes disciplines fait appel à une compréhension de la variabilité ainsi qu'à une connaissance des outils descriptifs et analytiques reliés à la variabilité.

- **Définition**

La statistique

- C'est l'art de recueillir, présenter, analyser et utiliser des observations (**des données**) afin d'aider à la prise de décisions et à la résolution de problèmes.
- Le premier phénomène qui ressort des observations: la **variabilité** des données.



Introduction

Statistique
Descriptive

Probabilité

Ajustement

Estimation



Introduction

Exemple

- On s'intéresse à un nouvel alliage aluminium et lithium; on analyse sa résistance à la compression.
- 80 tests sont effectués (les unités sont en psi)

105	221	183	186	121	181	180	143
97	154	153	174	120	168	167	141
245	228	174	199	181	158	176	110
163	131	154	115	160	208	158	133
207	180	190	193	194	133	156	123
134	178	76	167	184	135	229	146
218	157	101	171	165	172	158	169
199	151	142	163	145	171	148	158
160	175	149	87	160	237	150	135
196	201	200	176	150	170	118	149

Lire et interpréter
ces données???



Introduction

Statistique
Descriptive

Probabilité

Ajustement

Estimation




Introduction

Statistique

Statistique descriptive

s'occupe de la description des données: tableau, graphique, pourcentage, ...



Statistique inférentielle

s'occupe de tirer des conclusions générales à partir d'expériences et de faire des prévisions.

la résistance moyenne à la rupture de cet alliage se situe entre 155,3 et 170,1 psi ; cette affirmation possède un niveau de confiance de 95%.



Introduction

Statistique
Descriptive

Probabilité


Ajustement

Estimation



Introduction

- Comment faire une étude statistique?





Partie 1

Statistique descriptive



Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation



Statistiques Descriptive: Vocabulaire

Définitions

Population : On appelle population l'ensemble sur lequel porte notre étude statistique. Cet ensemble est noté Ω .

Exemples: l'ensemble des étudiants d'une classe, l'ensemble des véhicules susceptibles de circuler dans une ville,...

Individu : On appelle individu tout élément de la population Ω , il est noté ω (ω dans Ω)

Exemples: un étudiant, une voiture ,...

Caractère : On appelle caractère (ou variable statistique, dénotée V.S) toute application
$$X : \Omega \rightarrow C.$$

L'ensemble C est dit : ensemble des valeurs du caractère X (c'est ce qui est mesuré ou observé sur les individus)

Exemples: Taille, température, nationalité, couleur des yeux



Introduction

**Statistique
Descriptive**

Probabilité


Ajustement

Estimation



Statistiques Descriptive: Vocabulaire

Types des variables





Introduction

Statistique
Descriptive

Probabilité

Ajustement

Estimation



Statistiques Descriptive: variables

Étude d'une série statistique à variable discrète

x_i	n_i	f_i
x_1	n_1	f_1
x_2	n_2	f_2
...	...	...
x_p	n_p	f_p
$\sum_1^p$	n	1

x_1 est la plus petite valeur, x_p la plus grande des valeurs observées.

Chaque ligne correspond à une valeur observée différente. Il y a p valeurs différentes observées.

n_i correspond au nombre d'observations (effectif) ayant comme valeur x_i

f_i correspond à la fréquence (pourcentage) d'observations ayant comme valeur x_i :

$$f_i = \frac{n_i}{n}$$



Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation



Statistiques Descriptive: variables

Étude d'une série statistique à variable discrète

x_i	n_i	f_i	N_i	F_i
x_1	n_1	f_1	N_1	F_1
x_2	n_2	f_2	N_2	F_2
...	...	...		...
x_p	n_p	f_p	N_p	F_p
$\sum_1^p$	n	1		

N_i est l'effectif cumulé c'est dire le nombre d'observations ayant des valeurs inférieures ou égales à x_i :

$$N_i = \sum_{k=1}^i n_k$$

F_i est la fréquence cumulée c'est à dire la fréquence des observations ayant des valeurs inférieures ou égales à x_i :

$$F_i = \sum_{k=1}^i f_k$$



Introduction

Statistique
Descriptive

Probabilité

Ajustement

Estimation



Statistiques Descriptive: variables

Étude d'une série statistique à variable continue

- Les valeurs sont mises en **classes**.
- Leurs valeurs extrêmes sont appelées **bornes des classes**.
- Les classes **sont mutuellement exclusives**.
- L'**amplitude** de la classe ou **intervalle** ou **module** de classe :
 $\Delta = \text{borne supérieure} - \text{la borne inférieure}$.
- Le **point central** ou encore **point médian** est situé à mi chemin entre les bornes.
$$C_i = \frac{\text{inf de la classe } i + \text{sup de la classe } i}{2}$$
- L'intervalle de classe est généralement constant, toutefois, on utilise parfois une amplitude variable notamment pour les classes des valeurs extrêmes.
- En cas de classes d'amplitudes différentes, **la densité de fréquence n_i / D_i** permet de comparer les effectifs ou les fréquences d'une classe à l'autre.
- **la densité de fréquence** est utilisée pour tracer l'histogramme.



Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation



Statistiques Descriptive: variables

Étude d'une série statistique a variable continue

Classe	C_i	n_i	f_i	N_i	F_i
[140-160[	150,0	10	0,05	10	0,05
[160-165[	162,5	20	0,10	30	0,15
[165-170[	167,5	30	0,15	60	0,30
[170-175[	172,5	45	0,23	105	0,53
[175-180[	177,5	40	0,20	145	0,73
[180-185[	182,5	35	0,18	180	0,90
[185-190[	187,5	15	0,08	195	0,98
[190-200[	195,0	5	0,03	200	1,00

Pour les calculs, le centre de classe C_i est utilisé en remplacement de x_i

Remarque

- Pour les calculs des paramètres statistiques usuels des données quantitatives et uniquement de ce type de données.
- On complète la distribution par :
 - Une colonne $n_i * x_i$ pour calculer le **total**,
 - Une colonne $n_i * x_i^2$ pour calculer le **total des carrés**.



Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation



Statistiques Descriptive: représentation graphique

Distributions non cumulées

Distributions non groupées

- Données qualitatives :
 - **Diagramme sectoriel**
 - Angle au centre proportionnel à n_i (ou f_i).
- Données quantitatives discrètes
 - **Diagramme en bâtons**
 - On trace parallèlement à l'axe des ordonnées, en regard des x_i qui sont portés en abscisse, un segment de longueur proportionnel à n_i
 - **Polygone des fréquences**
 - Ligne brisée joignant les bâtons.
 - Fréquences absolues / fréquences relatives.



Statistiques Descriptive: représentation graphique

Distributions non cumulées

Introduction

**Statistique
Descriptive**

Probabilité

Ajustement


Estimation



Données qualitatives: Diagramme sectoriel

Répartition des groupes sanguins

Groupes sanguins	n_i	f_i
A	35	35%
B	9	9%
O	40	40%
AB	16	16%
	100	100%





Statistiques Descriptive: représentation graphique

Distributions non cumulées

Introduction

Statistique
Descriptive

Probabilité


Ajustement

Estimation



Données quantitatives discrètes

nombre d'enfants (xi)	nombre de familles (ni)
0	10
1	20
2	15
3	5
4	3
> 4	0



Polygone des fréquences



Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation



Statistiques Descriptive: représentation graphique

Distributions non cumulées

Distributions groupées

- Données quantitatives continues
 - **Histogramme :**
 - Composé de rectangles ayant comme base l'intervalle de classe et **comme hauteur la densité de fréquence (n_i/D_i)**.
 - La surface est proportionnelle à n_i .



Statistiques Descriptive: représentation graphique

Distributions non cumulées

Introduction

**Statistique
Descriptive**

Probabilité


Ajustement

Estimation



Histogramme

Classe	n_i	Densité (*10)
[140-160[	10	5
[160-165[	20	40
[165-170[	30	60
[170-175[	45	90
[175-180[	40	80
[180-185[	35	70
[185-190[	15	30
[190-200[	5	5






Statistiques Descriptive: représentation graphique

Distributions cumulées

Distributions cumulées

- Uniquement pour des données quantitatives
 - Polygone des fréquences :
 - Distributions non groupées = **escalier**.
 - Distributions groupées = ligne brisée.
 - Histogrammes.



Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation





Statistiques Descriptive: représentation graphique

Distributions cumulées

Asymétrie

L'asymétrie évalue dans quelle mesure vos données ne sont pas symétriques. Qu'elle soit de 0, positive ou négative, la valeur d'asymétrie fournit des informations sur la forme des données.




Figure A




Figure B

Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation





Statistiques Descriptive: représentation graphique

Distributions cumulées


Introduction

**Statistique
Descriptive**


Probabilité

Ajustement

Estimation



Distributions positives ou asymétriques à droite



Distributions négatives ou asymétriques à gauche




Statistiques Descriptive: représentation graphique


Distributions cumulées

Aplatissement


L'aplatissement indique dans quelle mesure les queues d'une loi diffèrent de la loi normale. Utilisez l'aplatissement pour mieux comprendre dès le départ les caractéristiques générales de la distribution de vos données.



Référence : valeur d'aplatissement de 0



Aplatissement positif



Aplatissement négatif

Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation





Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation



Statistiques Descriptive: variables

Étude d'une série statistique à variable discrète

Application 2

enquête réalisée auprès de 20 femmes casablancaises nées en 1970 sur le nombre d'enfants qu'elles ont eus

1. Peut on représenter cette distribution en classes? Si oui construire la table statistique correspondante puis dresser un graphe compatible?

Nombre d'enfants	Effectif de femmes
0	1
1	3
2	5
3	5
4	4
5	2



Statistiques Descriptive: paramètres statistiques

Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation

Paramètres statistiques

Une série de données peut être résumée par quelques valeurs numériques appelées caractéristiques des séries statistiques, classées en quatre grandes catégories :

- **Caractéristiques de tendance centrale (position).**
- **Caractéristiques de dispersion.**
- **Caractéristiques de forme.**
- **Caractéristiques de concentration.**





Introduction

Statistique
Descriptive

Probabilité

Ajustement

Estimation

Statistiques Descriptive: paramètres statistiques

Les paramètres de position: la moyenne

La **moyenne** se calcul en divisant la somme des valeurs par le nombre d'observations.

Propriétés

Moyen arithmétique:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k n_i x_i = \sum_{i=1}^k f_i x_i$$

La moyenne arithmétique permet de résumer par un seul nombre la série statistique.

- Elle prend en compte toutes les valeurs de la série et elle est facile à calculer.
- Elle est sensible aux valeurs extrêmes, il est parfois nécessaire de supprimer des valeurs extrêmes ou « aberrantes ».
- Mauvais résumé si la distribution est très dissymétrique.
- La quantité $e_i = x_i - \bar{x}$ est l'écart de la valeur x_i à la moyenne arithmétique. La moyenne arithmétique des écarts e_i est nulle.

Dans le cas continu, il suffit de remplacer les x par les centres des classes.





Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation

Statistiques Descriptive: paramètres statistiques

Les paramètres de position: le mode

Propriétés

Mode: Le mode est la valeur de la variable statistique la plus fréquente que l'on observe dans une série d'observations.

- Le mode n'existe pas toujours et quand il existe, il n'est pas toujours unique.
- Si après regroupement des données en classes, on trouve deux ou plusieurs modes différents, on doit considérer que l'on est en présence de deux ou plusieurs populations distinctes ayant chacune leurs caractéristiques propres ; dans ce cas, la moyenne arithmétique n'est pas une caractéristique de tendance centrale.





Statistiques Descriptive: paramètres statistiques

Les paramètres de position: le mode


Introduction

Statistique
Descriptive

Probabilité

Ajustement

Estimation



- Dans le cas continu, on dit une classe modale, la classe dont la fréquence est maximale.

Note	Fréquence absolue
x_i	n
1	2
2	1
3	0
4	2
5	3
6	0
7	1
8	2
9	5
10	1
11	4
12	8
13	2
14	9
15	6
16	2
17	0
18	1
19	1
20	0





Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation

Statistiques Descriptive: paramètres statistiques

Les paramètres de position: les quantiles

Les **quantiles** divise la distribution en plusieurs secteurs d'intérêt.

Quartiles

- **Q1**: 25% des valeurs sont inférieures au premier quartiles
- **Q2**: ou Médiane : 50% des valeurs sont inférieures au deuxième quartiles.
- **Q3**: 75% des valeurs sont inférieures au troisième quartiles.

Il est possible aussi de couper la distribution en:

- Déciles.
- Centiles.
- Percentiles particuliers.





Statistiques Descriptive: paramètres statistiques

Les paramètres de position: les quantiles



Introduction

Statistique
Descriptive

Probabilité

Ajustement

Estimation



	Note	Fréquence absolue
	x_i	n
	1	2
	2	1
	3	0
	4	2
	5	3
	6	0
	7	1
	8	2
Quartile 25%	9	5
	10	1
	11	4
Quartile 50%	12	8
	13	2
Quartile 75%	14	9
	15	6
	16	2
	17	0
	18	1
	19	1
	20	0





Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation

Statistiques Descriptive: paramètres statistiques

Les paramètres de position: la médiane

Médiane: cas discret

Pour déterminer la médiane, on utilise les effectifs cumulés croissants puis on distingue les cas suivants:

- Lorsque l'effectif total est un nombre impair (de type $N = 2n+1$), la médiane est la valeur prise par le $n+1$ i ème effectif.
- Lorsque l'effectif total est un nombre pair (de type $N = 2n$), la médiane est la valeur prise par la moyenne entre le n i ème effectif et le $n+1$ i ème effectif.

Exemple

Nombre d'enfants	0	1	2	3	4	5	6	7
Effectif	291	170	155	95	43	27	20	10
Effectif cumulé croissant	291	461	616	711	754	781	801	811

$$811 = 2 \times 405 + 1 \longrightarrow \text{Me} = 1$$





Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation

Statistiques Descriptive: paramètres statistiques

Les paramètres de position: la Médiane

Médiane: cas continu

- La classe médiane est la classe première classe pour laquelle la **fréquence cumulée** dépasse 0,5.
- Pour trouver la médiane, on applique la règle de Thalès a la classe médiane. (Voir exemple)

La médiane se trouve donc dans la classe médiane **[8;12[**

Exemple

Notes	Effectif
[0,5[	10
[5,8[	8
[8,12[	12
[12,15[	11
[15,20[	9
	50





Statistiques Descriptive: paramètres statistiques

Les paramètres de position: la Médiane


Introduction

Statistique
Descriptive


Probabilité

Ajustement

Estimation



Thalès



$$\frac{AC}{AD} = \frac{MC}{BD} \Leftrightarrow \frac{M_e - 8}{12 - 8} = \frac{25 - 18}{30 - 18} \Leftrightarrow M_e \approx 10,33$$





Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation

Statistiques Descriptive: paramètres statistiques

Les paramètres de position: la Médiane

Médiane: propriétés

Le calcul de la médiane est rapide.

- La médiane n'est pas influencée par les valeurs extrêmes ou aberrantes.
- La médiane est influencée par le nombre des données mais non par leurs valeurs, elle ne peut donc pas être utilisée en théorie de l'estimation.
- La médiane est le point d'intersection des courbes cumulatives croissante et décroissante.
- La médiane ne se prête pas aux combinaisons algébriques ; la médiane d'une série globale ne peut pas être déduite des médianes des séries composantes.





Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation

Statistiques Descriptive: paramètres statistiques

Les paramètres de dispersion

Ces paramètres rendent compte de l'étalement des données. Cela permet de montrer si les données sont éloignées ou proches de la moyenne.

Étendue, intervalle interquartile, écart à la moyenne, L'écart absolu moyen

- **Étendue:** Il s'agit de différence entre les valeurs extrêmes de la distribution.
- **IQR:** Il s'agit de la différence entre les valeurs du troisième et premier quartil.

$$\text{IQR} = Q3 - Q1$$

- **Écart à la moyenne:** Il s'agit des écarts de chaque valeur par rapport à la moyenne.
- **L'écart absolu moyen (EAM):** Il s'agit de la moyenne arithmétique des valeurs absolues des écarts de chaque valeur par rapport à la moyenne.





Statistiques Descriptive: paramètres statistiques

Les paramètres de dispersion: variance

Variance

Variance: noté s^2 , il s'agit de la moyenne des carrés des écarts ou variance empirique. Il rend compte de l'éloignement de chaque valeur par rapport à la moyenne.

$$e_q^2 = s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Qui peut être simplifiée par:

$$s^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2$$

Changement d'origine et d'échelle

$$s_{aX+b}^2 = a^2 s_X^2$$

Écart type: il s'agit de la racine carré de la variance.

$$\sigma = \sqrt{v(x)}$$

Introduction

Statistique
Descriptive

Probabilité

Ajustement

Estimation





Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation

Statistiques Descriptive: paramètres statistiques

Les paramètres de dispersion: variance

Écart type

L'écart-type s caractérise la dispersion d'une série de valeurs. Plus s est petit, plus les données sont regroupées autour de la moyenne arithmétique et plus la population est homogène.

L'écart-type permet de trouver le pourcentage de la population appartenant à un intervalle centré sur l'espérance mathématique.

La variance tient compte de toutes les données, c'est la meilleure caractéristique de dispersion (nombreuses applications en statistique).





Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation

Statistiques Descriptive: paramètres statistiques

Les paramètres de dispersion: variance

Coefficient de variation

Coefficient de variation: Il s'exprime, sous la forme d'un pourcentage, par l'expression suivante :

$$CV = \frac{s}{\bar{x}} \times 100$$

Propriétés

- Le coefficient de variation ne dépend pas des unités choisies.
- Il permet d'apprécier la représentativité de la moyenne arithmétique $\bar{x}$ par rapport à l'ensemble des données.
- Il permet d'apprécier l'homogénéité de la distribution, une valeur du coefficient de variation inférieure à 15 % traduit une bonne homogénéité de la distribution.
- Il permet de comparer deux distributions, même si les données ne sont pas exprimées avec la même unité ou si les moyennes arithmétiques des deux séries sont très différentes.

Exemple: Une distribution a une moyenne de 10 et un écart-type de 1 ($Cv = 10\%$), elle sera beaucoup plus dispersée qu'une distribution de moyenne 1000 et d'écart-type 10 (Cv de 1 %).





Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation

Statistiques Descriptive: paramètres statistiques

Les paramètres de forme: symétrie

Symétrie-asymétrie

Une distribution est symétrique si les valeurs de la variable statistique sont également distribuées de part et d'autre d'une valeur centrale. Pour une distribution symétrique :

mode = médiane = moyenne arithmétique

Coefficient d'asymétrie ou de dissymétrie ou skewness

$$\gamma_1 = \frac{\mu_3}{s^3} \quad \text{où} \quad \mu_3 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3$$

Coefficient d'aplatissement ou kurtosis

$$\gamma_2 = \frac{\mu_4}{s^4} \quad \text{où} \quad \mu_4 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4$$





Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation

Statistiques Descriptive: paramètres statistiques

Les paramètres de forme: symétrie

Symétrie-asymétrie

Ces deux coefficients sont principalement utilisés pour vérifier qu'une distribution est proche d'une distribution normale (loi de Laplace-Gauss) ; en effet, pour une telle loi, le coefficient d'aplatissement est égal à 3 et le coefficient d'asymétrie à 0. Selon la valeur de ces coefficients, on peut donner quelques caractéristiques sur la forme de la distribution :

- Si $\gamma > 0$, la distribution est étalée vers la droite.
- Si $\gamma < 0$, la distribution est étalée vers la gauche.
- Si $\gamma = 0$, on ne peut pas conclure que la distribution est symétrique mais la réciproque est vraie.
- Si $\beta > 3$, la distribution est moins aplatie qu'une distribution gaussienne.
- Si $\beta < 3$, la distribution est plus aplatie qu'une distribution gaussienne.







Statistiques Descriptive: paramètres statistiques

Les paramètres de forme: symétrie


Symétrie-asymétrie



Référence : valeur d'aplatissement de 0



Aplatissement positif



Aplatissement négatif

Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation





Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation

Statistiques Descriptive: paramètres statistiques

Les paramètres de concentration

Concentration

La courbe de concentration est réalisée à partir des calculs des fréquences cumulées croissantes et des masses cumulées croissantes.

Les fréquences cumulées croissantes sont placées en abscisses et les masses cumulées croissantes sont placées en ordonnées.

La distribution théorique d'égale répartition correspond à la bissectrice du repère.

L'aire comprise entre la distribution théorique et la courbe de concentration s'appelle la **surface de concentration**.






Statistiques Descriptive: paramètres statistiques

Les paramètres de concentration

Concentration

Courbe de Lorentz



Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation





Statistiques Descriptive: paramètres statistiques

Les paramètres de concentration

Concentration

Il s'exprime par

$$G = \frac{E}{2M}$$

Ou

$$E = \frac{1}{n^2} \sum_{i=1}^n \sum_{j=1}^n |x_i - x_j|$$

$$M = \frac{1}{n} \sum_{k=1}^n x_k$$

Si G est proche de 0: la courbe de Lorentz est proche de la diagonale, la concentration est faible. La concentration nulle correspond à une distribution égalitaire.

Si G est proche de 1: la concentration est forte.

Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation







Statistiques Descriptive: paramètres statistiques

Les paramètres de forme: symétrie


Symétrie-asymétrie



Référence : valeur d'aplatissement de 0



Aplatissement positif



Aplatissement négatif

Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation





Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation

Statistiques Descriptive: paramètres statistiques

Combinaison position/dispersion

Coefficient de variation: Il combine les paramètres de moyenne et d'écart type. Il permet de comparer 2 variables de nature différentes.

$$C_v = \frac{\sigma}{m} \times 100$$

Exemple: Une distribution a une moyenne de 10 et un écart-type de 1 (**Cv= 10 %**), elle sera beaucoup plus dispersée qu'une distribution de moyenne 1000 et d'écart-type 10 (**Cv de 1 %**).





Statistiques Descriptive

D'une donnée brute vers une donnée continue

Conversion d'une série discrete

La règle de **STURGE** : Nombre de classes = $1 + (3,3 \log n)$

La règle de **YULE** : Nombre de classes = $2,5 \sqrt[4]{n}$

L'**intervalle** entre chaque classe est obtenu ensuite de la manière suivante :

Intervalle de classe = $(X_{\max} - X_{\min}) / \text{Nombre de classes}$

avec $X_{\max}$ et $X_{\min}$, respectivement la plus grande et la plus petite valeur de X dans la série statistique.

Introduction

Statistique
Descriptive

Probabilité

Ajustement

Estimation





Statistiques Descriptive: Application

Étude d'une série statistique à variable discrète

Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation



Application

La brigade de police a effectuée un contrôle sur une artère de la capitale, et a relevé les infractions commises par les conducteurs contrôlés.

1. Déterminer la population, l'individu le caractère et l'ensemble des modalités.
2. Compléter cette étude statistique.

Nombre d'infractions	Nombre de conducteurs
0	44
1	140
2	92
3	156
4	256
5	80
6	32



Statistiques Descriptive: Application

Exercice 1.

Chez un fabricant de tubes de plastiques, on a prélevé un échantillon de 100 tubes dont on a mesuré le diamètre en décimètre

1.94	2.20	2.33	2.39	2.45	2.50	2.54	2.61	2.66	2.85
1.96	2.21	2.33	2.40	2.46	2.51	2.54	2.62	2.68	2.87
2.07	2.26	2.34	2.40	2.47	2.52	2.55	2.62	2.68	2.90
2.09	2.26	2.34	2.40	2.47	2.52	2.55	2.62	2.68	2.91
2.09	2.28	2.35	2.40	2.48	2.52	2.56	2.62	2.71	2.94
2.12	2.29	2.36	2.41	2.49	2.52	2.56	2.63	2.73	2.95
2.13	2.30	2.37	2.42	2.49	2.53	2.57	2.63	2.75	2.99
2.14	2.31	2.38	2.42	2.49	2.53	2.57	2.65	2.76	2.99
2.19	2.31	2.38	2.42	2.49	2.53	2.59	2.66	2.77	3.09
2.19	2.31	2.38	2.42	2.50	2.54	2.59	2.66	2.78	3.12

Introduction

Statistique
Descriptive

Probabilité

Ajustement

Estimation





Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation



Statistiques Descriptive: Application

Exercice 1.

1. Identifier la population, les individus, le caractère et son type.
2. En utilisant la méthode de **Yule** puis de **Sturge**, établir le tableau statistique (Faites débiter la première classe par la valeur 1.94).
3. Tracer l'histogramme de cette variable statistique.
4. Déterminer par le calcul la valeur du diamètre au-dessous de laquelle se trouvent 50% des tubes de plastique. Que représente cette valeur.
5. Déterminer par le calcul le pourcentage de tubes ayant un diamètre inférieur à 2.58.



Partie 2

Statistique bivariable



Statistiques Descriptive: cas de deux variables

Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation



Objectifs

La brigade On s'intéresse a deux variables x et y . Ces deux variables sont mesurées sur les n unités d'observation. Pour chaque unité, on obtient donc deux mesures. La série statistique est alors une suite de n couples des valeurs prises par les deux variables sur chaque individu.




Statistiques Descriptive: cas de deux variables

Représentation graphique

Nuage des points

Chaque couple est composé de deux valeurs numériques. Un couple de nombres (entiers ou réels) peut toujours être représenté comme un point dans un plan

Nuage des points



Nuage des points

y_i	x_i	y_i	x_i
60	155	75	180
61	162	76	175
64	157	78	173
67	170	80	175
68	164	85	179
69	162	90	175
70	169	96	180
70	170	96	185
72	178	98	189
73	173	101	187

Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation





Statistiques Descriptive: cas de deux variables

Analyse des variables.

Les variables x et y peuvent être analysées séparément. On peut calculer tous les paramètres dont les moyennes et les variances :

Nuage des points

$$s_y^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2$$

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$s_x^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$$

Ces paramètres sont appelés paramètres marginaux : variances marginales, moyennes marginales, écarts-types marginaux, quantiles marginaux, etc. . .

Introduction

Statistique
Descriptive

Probabilité

Ajustement

Estimation





Statistiques Descriptive: cas de deux variables

Covariance

Introduction

Statistique
Descriptive

Probabilité

Ajustement

Estimation



La covariance est définie par:

Covariance

$$s_{xy} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

- La covariance peut prendre des valeurs positives, négatives ou nulles.
- Quand $X_i = Y_i$, pour tout $i = 1, \dots, n$, la covariance est égale à la variance.
- On peut également l'écrire sous cette forme:

Covariance

$$\frac{1}{n} \sum_{i=1}^n x_i y_i - \bar{x} \bar{y}$$



Statistiques Descriptive: cas de deux variables

Corrélation

Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation



Le coefficient de corrélation est la covariance divisée par les deux écart-types marginaux :

Le coefficient de détermination est le carré du coefficient de corrélation :

Covariance de coorelation et de détermination

$$r_{xy}^2 = \frac{s_{xy}^2}{s_x^2 s_y^2}$$

$$r_{xy} = \frac{s_{xy}}{s_x s_y}$$



Introduction

**Statistique
Descriptive**

Probabilité

Ajustement

Estimation



Statistiques Descriptive: cas de deux variables

Corrélation

- Le coefficient de corrélation mesure la dépendance linéaire entre deux variables:

Corrélation

$$-1 \leq r_{xy} \leq 1$$

$$0 \leq r_{xy}^2 \leq 1$$

- Si le coefficient de corrélation est positif, les points sont alignés le long d'une droite croissante.
- Si le coefficient de corrélation est négatif, les points sont alignés le long d'une droite décroissante.
- Si le coefficient de corrélation est nul ou proche de zéro, il n'y a pas de dépendance linéaire. On peut cependant avoir une dépendance non-linéaire avec un coefficient de corrélation nul



Statistiques Descriptive: cas de deux variables

Covariance

Exemple


Introduction

Statistique
Descriptive

Probabilité

Ajustement

Estimation





Introduction

Statistique
Descriptive

Ajustement

Probabilité

Estimation



Statistiques Descriptive: cas de deux variables

Régression entre deux variables

Lorsque deux variables quantitatives sont correctement corrélées (S_{xy} voisin de 1) et que l'on peut considérer, a priori, que l'une (nous supposons qu'il s'agit de X) est cause de l'autre (il s'agira donc de Y), il est alors assez naturel de chercher une fonction de X approchant Y, "le mieux possible" en un certain sens. La méthode statistique permettant de trouver une telle fonction s'appelle la **régression** de Y sur X

La technique de régression s'appuie sur un choix adéquat d'une fonction qui représente de meilleure façon l'approximation de Y en fonction de X.

Si la fonction est linéaire, on dit que la **régression est linéaire**.
Dans le cas général, on parle de l'ajustement via les **moindres carrées**



Statistiques Descriptive: cas de deux variables

Régression linéaire

Il consiste à minimiser la quantité suivante :

$$F(a, b) = \sum_{i=1}^n (Y_i - (aX_i + b))^2$$

La solution de ce problème est donnée par:

$$a^* = \frac{s_{xy}}{s_x^2} \quad b^* = \bar{Y} - a^* \bar{X}$$

Introduction

Statistique
Descriptive

Ajustement

Probabilité

Estimation





Statistiques Descriptive: cas de deux variables

Méthode des moindres carrées

Introduction

Statistique
Descriptive

Ajustement

Probabilité

Estimation



Extremum des fonctions a plusieurs variables.

Les extrémums $\vec{x}^*$ sont définis en résolvant l'équation vectorielle :

$$\nabla f(\vec{x}^*) = 0$$

Ce qui est équivalent a résoudre le système suivant:

$$(4.2) \quad \begin{cases} \frac{\partial f}{\partial x_1}(\vec{x}^*) = 0 \\ \vdots \\ \frac{\partial f}{\partial x_m}(\vec{x}^*) = 0 \end{cases}$$



Statistiques Descriptive: cas de deux variables

Méthode des moindres carrées

Introduction

Statistique
Descriptive

Ajustement

Probabilité

Estimation



Extremum des fonctions a plusieurs variables.

En trouvant les différentes positions $\vec{x}^*$ les minimas et maximas sont définis par le signe du discriminant de la matrice hessienne au point $\vec{x}^*$. À la position $\vec{x}^*$, la matrice hessien est définie par l'expression suivante:

$$H_{x_1, \dots, x_m}(f(\vec{x}^*)) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2}(\vec{x}^*) & \dots & \frac{\partial^2 f}{\partial x_1 \partial x_m}(\vec{x}^*) \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_m \partial x_1}(\vec{x}^*) & \dots & \frac{\partial^2 f}{\partial x_m^2}(\vec{x}^*) \end{bmatrix}$$



Statistiques Descriptive: cas de deux variables

Méthode des moindres carrées

Extremum des fonctions a plusieurs variables.

Le discriminant de la matrice hessienne au point $\vec{x}^*$ est noté par $\Delta_H(\vec{x}^*)$

- $\Delta_H(\vec{x}^*) > 0 \rightarrow f(\vec{x}^*)$ est un minimum local (4.4)
- $\Delta_H(\vec{x}^*) < 0 \rightarrow f(\vec{x}^*)$ est un maximum local (4.5)

Cas de deux variables.

$$\begin{cases} \frac{\partial f}{\partial x_1}(x_1, x_2) = 0 \\ \frac{\partial f}{\partial x_2}(x_1, x_2) = 0 \end{cases}$$



$$H_{x_1, x_2}(f(x_1, x_2)) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2}(x_1, x_2) & \frac{\partial^2 f}{\partial x_1 \partial x_2}(x_1, x_2) \\ \frac{\partial^2 f}{\partial x_2 \partial x_1}(x_1, x_2) & \frac{\partial^2 f}{\partial x_2^2}(x_1, x_2) \end{bmatrix}$$



$$\Delta_H(x_1, x_2) = \frac{\partial^2 f}{\partial x_2 \partial x_1}(x_1, x_2) - \frac{\partial^2 f}{\partial x_1^2}(x_1, x_2) \frac{\partial^2 f}{\partial x_2^2}(x_1, x_2)$$

Introduction

Statistique
Descriptive

Ajustement

Probabilité

Estimation





Introduction

Statistique
Descriptive

Ajustement

Probabilité

Estimation



Statistiques Descriptive: cas de deux variables

Méthode des moindres carrées

Principe des moindres carrés .

Le principe des moindres carrés permet de trouver les valeurs optimales des paramètres d'un modèle en minimisant les écarts quadratiques entre les observations (ou expérimentations) et le modèles théoriques (empiriques) proposés.

Ce chapitre traite spécialement le cas de la modélisation de deux variables :

Variables endogène et exogène.

Variable exogène : dite variable indépendante, c'est la variable qui décrit le modèle, notée dans ce chapitre « x » ;

- **Variable endogène** : c'est la variable dépendante, représentant la variable ou le phénomène à modéliser en fonction de la variable exogène, notée dans ce chapitre « y ».



Statistiques Descriptive: cas de deux variables

Méthode des moindres carrées

Étapes d'application des moindres carrées.

L'application du principe des moindres carrés se divise en quatre principales étapes :

- Représentation des données $(x_i, y_i)_{1 \leq i \leq N}$ sur un graphique dans le plan $(\vec{X}, \vec{Y})$;
- Proposition d'une loi ou d'un ensemble de lois $(x, y(x))$ qui pourraient ajuster le nuage de point $(x_i, y_i)_{1 \leq i \leq N}$. Ces lois doivent nécessairement contenir des paramètres d'ajustement qui permettrait de les contrôler. Il est possible de distinguer différents types de paramètres :
 - Paramètres de position ;
 - Paramètres de forme ;
 - Paramètres d'échelle ;
- Ecriture analytique de l'expression de l'écart quadratique « Eq ». L'écart quadratique doit être explicité en fonction des paramètres cités ci-haut.
- Les paramètres optimaux sont déterminés par minimisation de l'écart quadratique « Eq » par rapport à ces derniers.

Introduction

Statistique
Descriptive

Ajustement

Probabilité

Estimation





Statistiques Descriptive: cas de deux variables

Méthode des moindres carrées

Application au modèle parabolique.(Voir TD)

Ajuster le modele non linéaire suivant:

$$f_{a,b,c}(x) = ax^2 + bx + c$$

Introduction

Statistique
Descriptive

Ajustement

Probabilité

Estimation





Partie 2

Probabilité



Statistiques Descriptive: cas de deux variables

Méthode des moindres carrées

Application au modèle parabolique.(Voir TD)

Ajuster le modele non linéaire suivant:

$$f_{a,b,c}(x) = ax^2 + bx + c$$

Introduction

Statistique
Descriptive

Ajustement

Probabilité

Estimation

